

Geração de Música por Meio de Inteligência Artificial Generativa

Lucas Vinícius de Carvalho Ikeda

Orientador: Prof. Dr. Danillo Roberto Pereira
Faculdade de Ciências e Tecnologia — UNESP

Defesa de TCC — 2026

Objetivo central

Gerar uma peça em formato .mid que um **humano reconheça como música** — mesmo simples — e **não confunda com ruído aleatório**.

- O critério de sucesso é, no fundo, **perceptual**.
- Por isso a avaliação final é feita com **ouvintes humanos** (MOS).
- A saída deve ser compatível com qualquer DAW (MuseScore, FL Studio).

Por que é difícil?

Música exige **coordenar quatro dimensões ao mesmo tempo**:

- **Melódica** — notas no tempo
- **Harmônica** — acordes
- **Rítmica** — padrões temporais
- **Tímbrica** — qual instrumento

O desafio

Não é gerar notas — é gerar notas **coordenadas** e com coerência de longo prazo. Modelos neurais sozinhos tendem a colapsar ou “perder o tempo”.

Transformer (a base do ChatGPT) usa **atenção** para capturar dependências longas:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$

Processa toda a sequência em paralelo, sem o gargalo das RNNs.

Tokenização REMI

Trata música como linguagem:


- NOTE_ON, NOTE_OFF
- VELOCITY, TIME_SHIFT
- BAR, BEAT (estrutura métrica)

- *Music Transformer* e *Pop Music Transformer* — mostraram que *Transformers* capturam regularidades musicais.
- *MuseGAN* (GANs), *MusicVAE* (VAE), *DeepBach* (restrições harmônicas).

A lacuna que preencho

Fazer funcionar com **recursos modestos** (uma GPU de 8 GB), **combinando a rede neural com teoria musical**.

Visão Geral: um sistema híbrido



A ideia-chave: o **modelo aprende**, e a **teoria musical dá os trilhos**.

Modelo (compacto)

- *Decoder-only* (estilo GPT)
- **3,2 milhões** de parâmetros
- d_model 256, 4 camadas, 4 cabeças
- Cabe em **8 GB** de VRAM (AMP)

Dados (3 datasets)


- *MAESTRO* — piano clássico
- *POP909* — pop multi-voz
- *Groove* — bateria humana

Modelo menor generaliza melhor em bases de tamanho moderado — e o gargalo não era tamanho, era calibração da perda.

O problema do *mode collapse* (e a solução)

- O modelo **travava** numa díade fixa após dezenas de notas.
- Diagnóstico: **overconfidence** no TIME_SHIFT.
- Solução: **label smoothing** (0,1) — mantém incerteza saudável.
- Foi a intervenção que **destravou** os resultados.

Gargalo era calibração da perda, não o tamanho do modelo.



Exemplo de colapso: duas notas fixas por toda a peça.

Geração com Restrições (*Constrained Decoding*)


Quatro estágios que guiam a amostragem sem substituir o modelo:

- 1 **Restrições de vocabulário** — gramática + harmonia da tonalidade.
- 2 **Re-entry bias** — “convite” para a voz calada voltar.
- 3 **Separação de vozes** por registro (solo / base / baixo).
- 4 **Fundação harmônica** opcional (`--solid_base`) — robustez.

As restrições **não criam** a música — elas **direcionam** o que o modelo aprendeu para regiões coerentes.


Resultados Quantitativos — *Transformer* vs Markov

Métricas Quantitativas por Amostra — Transformer vs Markov



- Markov “vence” algumas métricas — mas porque **copia** trechos do *dataset*.
- Na **regularidade rítmica** (*ioi_std*) o sistema vence com folga: **0,17 vs 0,32**.
- Métrica isolada não mede musicalidade $\Rightarrow$ MOS é o juiz.

Resultados Qualitativos + Demonstração



Transformer (acima): 3 camadas. *Markov* (abaixo): disperso.



- *Transformer*: três camadas coordenadas (solo, base, baixo).
- *Markov*: dispersão sem função nem fundação rítmica.

Demonstração (áudios)

Markov (caos) → **modelo sozinho** → sistema completo. **[tocar trechos]**

Avaliação Subjetiva (MOS) — $N = 25$ avaliadores

Avaliação Subjetiva (MOS) — $N = 25$ avaliadores



O **Transformer** vence os **4 critérios** ($p < 0,01$) e é percebido como **humano por 58%** dos avaliadores — contra 20% do Markov.

- **Critério atendido e validado:** a saída é reconhecida como música por ouvintes humanos — confirmado pelo MOS ($p < 0,01$), em nítido contraste com o caos do Markov.
- **Contribuição:** um *pipeline* híbrido (rede neural + teoria musical) que roda em hardware modesto, com diagnóstico e solução do *mode collapse*.
- **Trabalhos futuros:** modelo dedicado de bateria; condicionamento por estilo; comparação com modelos maiores.

Obrigado!

Perguntas?

Lucas Vinícius de Carvalho Ikeda
l.ikeda@unesp.br